

EM 算法

QwanxingxuA

2026 年 8 月 25 日

EM 算法由 E 步即期望步和 M 步即最大步构成，表面是一种策略 Q ，但其本质实际上算法。本文将以数学推导说明算法的由来。

提示：本文基本是数学推导，解决数学优化问题，李航老师的书是有所省略的，建议读者自己完整推导一遍，笔者的推导应该算很详尽的，也把笔者认为李航老师舍去的部分说了出来，可以参考。

1 模型与策略

EM 算法是解决隐变量概率模型的算法。产生的理由和最大熵模型类似，最大熵模型难以优化，但是好消息是能够找到等价的极大似然法，但是隐变量概率模型难以找到等价的算法，于是采用近似的方法，EM 算法因此诞生。

于是我们先看模型和策略本身。

定义可观测数据 x ，隐变量 z 。模型是可观测数据的似然概率模型：

$$P(\mathbf{x} | \theta)$$

其中， $\mathbf{x}$ 是观测数据； θ 是模型参数。

对于这种概率模型，依照常规，使用极大对数似然法策略：

$$L(\theta) = \log P(\mathbf{x} | \theta)$$

$$P(\mathbf{x} | \theta) = \sum_z P(\mathbf{z} | \theta) P(\mathbf{x} | \mathbf{z}, \theta)$$

但是解决上述极大似然问题是很难的，我们需要某种算法解决该问题。

2 EM 算法

对于难以直接求解的问题，我们往往会使用梯度下降的方法，但是此处并不容易，因为这个表达式是很难直接显示的，但是笔者似乎想到了一个方法，就是变分，因为变分就是处理这种表达式并不能直接表达参数 θ 的方法。先不管变分，不能梯度下降但是可以参考梯度下降的思想，就是一步一步迭代使得目标函数下降。所以可以尝试一下构建下降迭代：

$$L(\theta) - L(\theta^{(t)})$$

其中, θ 是 $\theta^{(t+1)}$, 这是为了书写方便，下将 $\theta^{(t)}$ 写作 θ^t 。

$$\begin{aligned} L(\theta) - L(\theta^t) &= \log \sum_z P(z | \theta) P(x | z, \theta) - \log P(z | \theta^t) \\ &= \log \sum_z P(z | x, \theta^t) \frac{P(z | \theta) P(x | z, \theta)}{P(z | x, \theta^t)} - \log P(z | \theta^t) \\ &= \log \sum_z P(z | x, \theta^t) \frac{P(z | \theta) P(x | z, \theta)}{P(z | x, \theta^t) P(x | \theta^t)} \end{aligned}$$

注意到

$$\sum_z P(z | x, \theta^t) = 1$$

由 Jensen 不等式：

$$L(\theta) - L(\theta^t) \geq \sum_z P(z | x, \theta^t) \log \frac{P(z | \theta) P(x | z, \theta)}{P(z | x, \theta^t) P(x | \theta^t)}$$

虽然似乎不能直接取得下降多少的表达式，但是有了新的发现，就是找到了 L 的下界限：

$$B(\theta, \theta^t) = L(\theta^t) + \sum_z P(z | x, \theta^t) \log \frac{P(z | \theta) P(x | z, \theta)}{P(z | x, \theta^t) P(x | \theta^t)}$$

于是我们想到了一个近似方法，通过提升 B 来极大化 L ，虽然我们无法确保 L 在提升，但是这也算退而求其次的方法。将表达式无关项简化做等价优化变化：

$$\begin{aligned} \theta^{(t+1)} &= \arg \max_{\theta} \sum_z P(z | x, \theta^t) \log P(z | \theta) P(x | z, \theta) \\ &= \arg \max_{\theta} Q(\theta, \theta^t) \end{aligned}$$

这边是 EM 算法表面上的策略了。但这是题外话，我们依旧是在解决原始策略的过程中。

这种方法可行吗？不能说下界提升， L 也在提升。那只能代入尝试一下了，即说明 L 单调递增。前面说了，求导不现实，这时候依旧想到构造减法：

可以直接相减，但是有更聪明的方法，即我们既然已经有了 Q ，当然化简表达式更好处理。

$$P(\mathbf{x} | \theta) = \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{P(\mathbf{z} | \mathbf{x}, \theta)}$$

这里李航老师书中也有，但是没有过多介绍，实际上这里有很大误区，很容易误导人。在之前我们定义过

$$P(\mathbf{x} | \theta) = \sum_{\mathbf{z}} P(\mathbf{z} | \theta) P(\mathbf{x} | \mathbf{z}, \theta)$$

表面上上面两个表达式不相等，因为一个求和一个没有求和。实际上是等价的，一个是全概率公式一个就是普通的条件概率变形。出现的原因是李航老师都写的是向量 $\mathbf{z}$ ，也应该这样写，因为这里的 $\mathbf{z}$ 取标量取向量都是应该的。

$$L(\theta) = \log P(\mathbf{x}, \mathbf{z} | \theta) - \log P(\mathbf{z} | \mathbf{x}, \theta)$$

两边乘 $P(\mathbf{z} | \mathbf{x}, \theta^t)$ 然后关于 $\mathbf{z}$ 求和：

$$\sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) L(\theta) = \sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) \log P(\mathbf{x}, \mathbf{z} | \theta) - \sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) \log P(\mathbf{z} | \mathbf{x}, \theta)$$

依旧注意到

$$\sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) = 1$$

且等式左边表达式与 $\mathbf{z}$ 无关，只与 θ 有关，于是

$$L(\theta) = \sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) \log P(\mathbf{x}, \mathbf{z} | \theta) - \sum_{\mathbf{z}} P(\mathbf{z} | \mathbf{x}, \theta^t) \log P(\mathbf{z} | \mathbf{x}, \theta)$$

可以惊喜的发现左侧是 $Q(\theta, \theta^t)$ ，将右侧记作 $H(\theta, \theta^t)$ ：

$$L(\theta) = Q(\theta, \theta^t) - H(\theta, \theta^t)$$

这个表达式太漂亮了，于是我们回到原本的任务，即说明单调递增。

在此之前，要说明李航老师书中另一个容易误解的地方了： L, Q, H 都是关于 θ 的函数，虽然我们看上去它像是关于 θ, θ^t 的函数，实际上就推导

过程来看，可以发现 θ^t 是参数，可以随便取。如果接触过共轭梯度法应该就不会有错误。弄清楚这一点了就可以得到

$$L(\theta) - L(\theta^t) = [Q(\theta, \theta^t) - Q(\theta^t, \theta^t)] - [H(\theta, \theta^t) - H(\theta^t, \theta^t)]$$

上面说过， Q 是用来求极大化问题的，显然上式第一项大于 0。看第二项：

$$\begin{aligned} H(\theta, \theta^t) - H(\theta^t, \theta^t) &= \sum_z \log \frac{P(zP(z | \mathbf{x}, \theta^t) | \mathbf{x}, \theta)}{P(z | \mathbf{x}, \theta^t)} \\ &\leq \log \sum_z P(z | \mathbf{x}, \theta^t) \frac{P(z | \mathbf{x}, \theta)}{P(z | \mathbf{x}, \theta^t)} \\ &= \log \sum_z P(z | \mathbf{x}, \theta) \\ &= 0 \end{aligned}$$

综上， $L(\theta)$ 确实单调递增。

还差一步，就是 R 提升， L 提升，它会不会一直提升呢？如果这样显然方法就不行。其实这就是收敛问题。既然序列单调递增，那这个问题也不复杂了，只需要有界即可。显然

$$L(\theta) = \log P(\mathbf{x} | \theta) \leq 0$$

所以走到这里，我们惊喜的找到了解决原问题的办法。这就是 EM 算法。回顾一下，E 步就是前面的求和，只不过科学家喜欢用更加高级的方式表达。

$$Q(\theta, \theta^t) = \mathbb{E}_{P(z | \mathbf{x}, \theta^t)} \log P(\mathbf{x}, z | \theta)$$

3 EM 算法的高斯混合模型应用

第一节的推导是基于普遍问题的，EM 算法本身也是因为表达式难以直接优化产生的。当遇到具体问题的时候，表达式会发生变化，但其 EM 本质是一样的。下面就以高斯混合模型为例，具体推导 EM 算法。

高斯混合模型：

$$\begin{aligned} p(\mathbf{x} | \theta) &= \sum_{j=1}^K \pi_j f(\mathbf{x} | \theta_j) \\ \theta_j &= (\mu_j, \sigma_j^2) \end{aligned}$$

$$f_j(\mathbf{x} | \theta_j) = \frac{1}{\sqrt{2\pi}\sigma_j} \exp \left\{ -\frac{(x - \mu_j)^2}{2\sigma_j^2} \right\}$$

$$\sum_{j=1}^K \pi_j = 1$$

可以把该模型理解成，学习权重从而学习样本由哪个高斯模型决定。于是可以定义隐变量 z ，表示第几个模型，这有点类似分类模型，为了方便，我们将其转换为独热编码向量

$$\mathbf{z} = (z_1, z_2, \dots, z_K)$$

或者

$$z_j = \begin{cases} 1, & \text{样本由第 } j \text{ 个模型决定} \\ 0, & \text{否则} \end{cases}$$

于是对于可观测数据 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 有隐变量 $\mathbf{z} = (z_1, z_2, \dots, z_n)$ ，其中 $\mathbf{z}_i = (z_{i1}, z_{i2}, \dots, z_{iK})$ 。理解这几个关系是十分必要的，尤其是哪些是标量哪些是向量以及哪些是矩阵（如果你不知道笔者说的矩阵是什么，那说明你很有必要仔细梳理一下这些变量了），如果不理清楚，下面的推导是很难进行的，或者说李航老师的书你将看的糊里糊涂。

当然这里可以尝试一下极大似然法，笔者就不赘述了，直接代入 EM 算法。

先求

$$\log P(\mathbf{x}, \mathbf{z} | \theta)$$

需要提醒的是以下推导是概率密度，其实 EM 算法使用概率密度的形式是一样的；其次第一节推导是基于单一样本的，实际上多个样本也就是在最终表达式前面求和，读者自行推导。

$$\begin{aligned} \log p(\mathbf{x}, \mathbf{z} | \theta) &= \log \prod_{i=1}^n \prod_{j=1}^K [\pi_j f(x_i | \theta_j)]^{z_{ij}} \\ &= \sum_{i=1}^n \sum_{k=1}^K z_{ik} \log \pi_k f(x_i | \theta_k) \end{aligned}$$

$$\begin{aligned} Q(\theta, \theta^t) &= \mathbb{E}_{p(\mathbf{z} | \mathbf{x}, \theta^t)} \log p(\mathbf{x}, \mathbf{z} | \theta) \\ &= \sum_{j=1}^K \sum_{i=1}^n \mathbb{E}_{p(\mathbf{z} | \mathbf{x}, \theta^t)}(z_{ij}) \log \pi_j f(x_i | \theta_j) \end{aligned}$$

以上推导是很显然的，但是为什么会这么轻松呢。这里涉及的技巧就是使用随机变量的方法，上面把所有都看作随机变量。如果没有这样看呢，笔者最初的时候就没有这样看，后面发现自己推错了。下面写出没想到随机变量的情况。

假设不以随机变量着手，我们就不是以随机变量

$$\log p(\mathbf{x}, \mathbf{z} \mid \theta)$$

入手了。而是

$$\begin{aligned}\log p(\mathbf{x}, z_j \mid \theta) &= \log \prod_{i=1}^n (\pi_j f(\mathbf{x} \mid \theta_j))^{z_{ij}} \\ &= \sum_{i=1}^n z_{ij} \log(\pi_j f(\mathbf{x} \mid \theta_j)) \\ Q &= \sum_{i=1}^n \sum_{j=1}^K p(z_{ij} \mid \mathbf{x}_i, \theta^t) z_{ij} \log(\pi_j f(\mathbf{x} \mid \theta_j))\end{aligned}$$

于是得到

$$\begin{aligned}\sum_{j=1}^K \sum_{i=1}^n p(z_{ij} \mid \mathbf{x}_i, \theta^t) z_{ij} \log(\pi_j f(\mathbf{x} \mid \theta_j)) &= \\ \sum_{j=1}^K \sum_{i=1}^n \mathbb{E}_{p(\mathbf{z} \mid \mathbf{x}, \theta^t)}(z_{ij}) \log \pi_j f(x_i \mid \theta_j)\end{aligned}$$

于是得到了李航老师书中的：

$$\mathbb{E}_{p(\mathbf{z} \mid \mathbf{x}, \theta^t)}(z_{ij}) = p(z_{ij} \mid \mathbf{x}_i, \theta^t) z_{ij} = p(z_{ij} = 1 \mid x_i, \theta^t)$$

这个等式可以说是非常关键的，李航老师直接给出来，当然直接给出来是正确的。但是如果有和笔者一样没有深入研究概率的，会不好理解。

从随机变量的角度， z_{ij} 是 0-1 分布，期望就是为 1 的概率，所以上式成立。

但是回顾 EM 算法推导过程，我们考虑

$$P(\mathbf{x} \mid \theta) = \sum_{\mathbf{z}} P(\mathbf{z} \mid \theta) P(\mathbf{x} \mid \mathbf{z}, \theta)$$

经过变化推导：

$$Q = \sum_{\mathbf{z}} P(\mathbf{z} \mid \mathbf{x}, \theta^t) \log P(\mathbf{z} \mid \theta) P(\mathbf{x} \mid \mathbf{z}, \theta)$$

然后得到

$$Q = \mathbb{E}_{P(\mathbf{z}|\mathbf{x},\theta^t)} \log P(\mathbf{x}, \mathbf{z} | \theta^t)$$

这里最后一步笔者只是提到一句随机变量，没想到在后来的推导给了我惨痛的教训。这一步不仅仅是等价变化。我们要求的不完全似然概率 $P(\mathbf{x} | \theta)$ ，由随机变量 $P(\mathbf{x}, \mathbf{z} | \theta)$ 即完全数据似然概率的期望近似解决。

即 EM 算法实现了从似然估计到求取期望的转变，这是多么伟大的转变。

好了，下面继续回到本问题。利用贝叶斯公式：

$$\begin{aligned} \mathbb{E}_{p(\mathbf{z}|\mathbf{x},\theta^t)}(z_{ij}) &= p(z_{ij} = 1 | x_i, \theta^t) \\ &= \frac{p(z_{ij} = 1, x_i | \theta^t)}{\sum_{j=1}^K p(z_{ij} = 1, x_i | \theta^t)} \\ &= \frac{p(x_i | z_{ij} = 1, \theta^t)}{\sum_{j=1}^K p(x_i | z_{ij} = 1, \theta^t)} \\ &= \frac{\pi_j f(x_i | \theta_j)}{\sum_{j=1}^K \pi_j f(x_i | \theta_j)} \end{aligned}$$

将上式记作：

$$\gamma_{ij} = \frac{\pi_j f(x_i | \theta_j)}{\sum_{j=1}^K \pi_j f(x_i | \theta_j)}, \quad i = 1, 2, \dots, n$$

于是：

$$Q = \sum_{j=1}^K \sum_{i=1}^n \gamma_{ij} \log \pi_j f(x_i | \theta_j)$$

关于 Q 的优化问题，很简单，读者自行推导：

$$\begin{aligned} \mu^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} x_i}{\sum_{i=1}^n \gamma_{ij}^{(t)}} \\ \sigma^{2(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ij}^{(t)} (x_i - \mu^{(t+1)})^2}{\sum_{i=1}^n \gamma_{ij}^{(t)}} \\ \pi_j^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ij}^{(t)}}{n} \end{aligned}$$

终于也是推完了，依旧不算容易，建议读者自己推导一遍。

4 变分 EM 算法

回顾 EM 算法，解决的问题是极大似然概率 $P(\mathbf{x} | \theta)$ 难以优化的问题。于是通过全概率公式和 Jensen 不等式得到另一个便于求解的优化问题。

但是，上一个解决办法是分子分母同时乘一个概率，这个技巧其实在求什么地方都能用，只是在 EM 中通过相减发现了一个很好的乘子

$$P(\mathbf{z} | \mathbf{x}, \theta^t)$$

这个表达式方便构造迭代。但是我们可以胆子大一点，假设存在某分布 $\tilde{P}(\mathbf{z})$

$$P(\mathbf{x} | \theta) = \sum_{\mathbf{z}} \tilde{P}(\mathbf{z}) \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{\tilde{P}(\mathbf{z})}$$

由 Jensen 不等式

$$\log P(\mathbf{x} | \theta) \geq \sum_{\mathbf{z}} \tilde{P}(\mathbf{z}) \log \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{\tilde{P}(\mathbf{z})} = \mathbb{E}_{\tilde{P}(\mathbf{z})} \log \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{\tilde{P}(\mathbf{z})}$$

所以我们添加了一个新的参数 $\tilde{P}(\mathbf{z})$ 。

但是我们其实也列过另一个表达式：

$$P(\mathbf{x} | \theta) = \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{P(\mathbf{z} | \mathbf{x}, \theta)}$$

我们之所以难以解决问题，是因为 $P(\mathbf{x} | \theta)$ 和 θ 没有直接关系，但是必须说明的一点是， $P(\mathbf{x} | \theta)$ 是可以通过数据估计的，即可以认为这个概率我们知道。再看所以只要后面分式的概率知其一就能知道另一个。但是这两个概率涉及隐变量我们很难直接表达，于是纳入变分的思想，将 $P(\mathbf{z} | \mathbf{x}, \theta)$ 加入扰动得到 $\tilde{P}(\mathbf{z})$ 。

我们的根本任务是找到分母的表达式。显然 $\tilde{P}(\mathbf{z})$ 与 $P(\mathbf{z} | \mathbf{x}, \theta)$ 相差太大是不行的。于是引入 KL 散度：

$$\begin{aligned} KL(\tilde{P}(\mathbf{z}) || P(\mathbf{z} | \mathbf{x}, \theta)) &= \mathbb{E}_{\tilde{P}(\mathbf{z})} [\log \tilde{P}(\mathbf{z}) - \log P(\mathbf{z} | \mathbf{x}, \theta)] \\ &= \mathbb{E}_{\tilde{P}(\mathbf{z})} [\log \tilde{P}(\mathbf{z}) - \log P(\mathbf{x} | \theta) P(\mathbf{x}, \mathbf{z} | \theta)] \\ &= \log P(\mathbf{x} | \theta) - \{\mathbb{E}_{\tilde{P}(\mathbf{z})} \log \tilde{P}(\mathbf{z}) - \mathbb{E}_{\tilde{P}(\mathbf{z})} \log P(\mathbf{x}, \mathbf{z} | \theta)\} \end{aligned}$$

故而想法是使得 KL 最小。但是发现了很有意思的地方。

上面我们走了两条方向，通过 Jensen 不等式得到了一个下界

$$\sum_z \tilde{P}(z) \log \frac{P(\mathbf{x}, z | \theta)}{\tilde{P}(z)} = \mathbb{E}_{\tilde{P}(z)} \log \frac{P(\mathbf{x}, z | \theta)}{\tilde{P}(z)} = \mathbb{E}_{\tilde{P}(z)} \log \tilde{P}(z) - \mathbb{E}_{\tilde{P}(z)} \log P(\mathbf{x}, z | \theta)$$

再看看 $KL \geq 0$ 呢。会发现具有相同的下界结论。

所以以上方法统一起来就是找到接近 $P(\mathbf{x}, z | \theta)$ 的近似概率分布，这样简化表达式从而便于优化 Q 步。

这个方法完整吗？基于变分的结论， $L(\tilde{P}(z, \theta))$ 是递增有界即收敛的。但是对应的似然概率 $P(\mathbf{x} | \theta)$ 不一定增加。但是这是一种近似方法，机器学习很多问题是难以找到最终解的。我们的首要目标是使得目标尽量靠近，至于找到最终的最优解，不是非必须的。从某种角度来看，能找到最优解的模型往往性能更差，机器学习的泛化能力也是必须要考虑的。