

PCA

QwanxingxuA

2026 年 9 月 1 日

1 PCA

PCA 即主成分分析，它是使用正交变换将线性相关的变量转换为线性无关的变量。在数据处理中，通常使用相关性热力图来看变量间的线性相关性，对于强相关的变量我们会采取诸如合并、舍去其一等方法优化数据，但是显然此类方法是粗略的。

何为主成分？字面意思就是主要的成分，换言之就是无线性相关的数据，因为它们主要是的。

如何分析呢？理解主成分过后很简单了，正交变换过后的数据特征一定线性无关。但是这一映射过程会出现信息压缩或者说损失，我们不希望信息丢失太多。怎么分析这种信息问题，在 SVD 里面的分解借用奇异值，实际上奇异值是特征值的变形，特征值是很有用的，可以以特征值为桥梁搭建联系。这就是 PCA。

笔者在 SVD 那一章写道奇异值分解降维，实际上与 PCA 是一致的。后续笔者将详细介绍，并从 SVD 和 PCA 探索它们在降维上面到底干了什么。

定义输入 $\mathbf{x} \in \mathbb{R}^m$ ，输出 $\mathbf{y} \in \mathbb{R}^m$ 。定义模型

$$y_k = \boldsymbol{\alpha}_k^T \mathbf{x}, \quad k = 1, 2, \dots, m$$

$$\boldsymbol{\alpha}_i \boldsymbol{\alpha}_j = 0, \quad i \neq j, i = 1, 2, \dots, m \quad j = 1, 2, \dots, m$$

$$\boldsymbol{\alpha}_k^T \boldsymbol{\alpha}_k = 1$$

2 变量

PCA 的操作往往都是针对坐标轴上生硬的数据执行的，这会导致使用者浅显的数据直觉。实际上，PCA 针对的对象是随机变量，所以 PCA 仍然逃不开机器学习的概率范式。在前几章的笔记中，笔者特别强调概率范式下的模型定义：

$$f: \mathbf{x} \rightarrow y$$

这是总体随机变量 $\mathbf{x}$ 的模型。这意味着还有随机变量 $\mathbf{x}_i$ 的模型

$$f: \mathbf{x}_i \rightarrow y$$

实际上这就是总体主成分分析和样本主成分分析模型，它们并不完全一样。

笔者强调一点，坐标轴依旧是随机变量，不能理解成一个数，而是坐标轴向量 $\mathbf{x} = \mathbf{e}_i$ 。

3 总体主成分分析

既然是考虑线性相关问题，自然可以纳入成熟的数学工具。

协方差矩阵

$$\Sigma = \text{Cov}(\mathbf{x}) = \mathbb{E}(\mathbf{x} - \mathbb{E}\mathbf{x})(\mathbf{x} - \mathbb{E}\mathbf{x})^T$$

相关矩阵

$$\mathbf{R} = \left[\frac{\text{Cov}(x_i, x_j)}{\sqrt{\text{Var}(x_i) \text{Var}(x_j)}} \right]_{m \times m}$$

采用怎样的策略呢。正交变换方式是很多的，PCA 希望保留更多信息。所以按照信息保留程度选取模型。直观的来看，数据映射过后距离拉得越开，信息保留的往往越多，而拉得开可以使用方差：

$$\text{Var}(\mathbf{x}) = \mathbb{E}(\mathbf{x} - \mathbb{E}\mathbf{x})^2 = \Sigma$$

于是算法迎刃而解了。定义 $\mathcal{W}$ 为已经选取的模型。

$$\begin{aligned} \max_{\alpha_k} \text{Var}(y_k) &= \text{Var}(\alpha_k^T \mathbf{x}) = \alpha_k^T \Sigma \alpha_k \\ s.t. \alpha_k^T \alpha_k &= 1, \\ \alpha_k \alpha_i &= 0, \quad \alpha_i \in \mathcal{W} \end{aligned}$$

解决这个优化问题比较简单。通过归纳法构造过拉格朗日函数求导即可，具体可以参考共轭梯度法。当然共轭梯度法比这个构造要复杂。但是解决了共轭构造，这类问题就不算难了。笔者不再赘述，给出结论：

$$\Sigma \alpha_k - \lambda_k \alpha_k$$

其中， λ_k 为第 k 步的拉格朗日乘子。

可以发现， λ_k 就是 Σ 的特征值，对应的单位特征向量为 α_k 。

那么令 $A = [\alpha_1 \ \alpha_2 \ \dots \ \alpha_m]$ ，有

$$\Sigma A = A \Lambda$$

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_k)$$

由于

$$A A^T = A^T A = I$$

所以

$$\Sigma = A \Lambda A^T$$

所以

$$\text{Cov}(\mathbf{y}) = [\alpha_k^T \Sigma \alpha_k]_{m \times m} = \Lambda$$

推导了这么多，总结一下到底是什么结论。

第一，正交变换向量就是协方差矩阵的单位特征向量。

$$\mathbf{y}_k = \alpha_k \mathbf{x}$$

第二，变化过后的方差矩阵（也可以说是协方差矩阵）就是由特征值组成的对角矩阵。

$$\text{Var}(\mathbf{y})_k = \lambda_k$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$$

所以通过特征向量实现主成分提取，通过特征值分析信息保留程度。这样就完成了机器学习任务！

4 PCA 与 SVD

二者的思想方法可以说一致，只是方向不同。但是它们的根源都是半正定实对称矩阵。SVD 利用半正定实对称矩阵：

$$\mathbf{A}^T \mathbf{A}$$

PCA 利用半正定实对称矩阵即协方差矩阵：

$$\text{Cov}(x) = \Sigma$$

再看正交矩阵构造。SVD 构造奇异值矩阵和特征向量矩阵，然后构造 $\mathbf{U}$ ，于是得到三层变换：正交旋转变换、坐标轴缩放、正交旋转变换。

$$\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^T$$

PCA，通过构造正交矩阵得到最优化问题，解问题的过程发现本质是特征值和单位向量。

$$\Sigma \alpha_k = \lambda_k \alpha_k$$

发现没有，PCA 是一个正交旋转，而 SVD 是分解成三个变换过程！而这根源是两种方法选择的半正定实对称矩阵的不同，也可以说是分解的出发点不一样。

PCA 和 SVD 最大的相同点，就是是对称矩阵的对角化。正因如此，它们本质是一样的，要理解这一点，先统一它们的随机变量都是样本随机变量。

对于样本随机变量，样本方差是

$$\text{Var}(x) = \frac{1}{n-1} \sum_{i=1}^n \text{Var}(x_i)$$

将样本数据规范化：

$$x = \frac{x - \bar{x}}{\sqrt{\text{Var}(x)}}$$

相关矩阵或者协方差矩阵（标准化过后是一个矩阵，为了统一说法，下说相关矩阵）。

$$\mathbf{R} = \frac{1}{n-1} \mathbf{X} \mathbf{X}^t$$

下使用 SVD 表达式：

$$\mathbf{A} \mathbf{A}^T = \mathbf{U} \Sigma \mathbf{V}^T \mathbf{V} \Sigma^T \mathbf{U}^T = \mathbf{U} \Sigma \Sigma^T \mathbf{U}^T$$

如果理解了 SVD，就会发现 $\Sigma_{SVD} \Sigma_{SVD}^T = \Sigma_{PCA}$

于是 $\mathbf{A}\mathbf{A}^T$ 就是协方差矩阵，所以对应的特征向量矩阵 $\mathbf{U}$ 就是正交变换的解。

哈哈，笔者说了这么多。实际上是一直没说

$$\mathbf{A} = \mathbf{X}$$

反而证明它们是一致的。

对于信息的考量了，笔者在 SVD 说了，SVD 的截断分解具有 PCA 的效果。

总结一下，标准化过后的样本 PCA 和 SVD 是一致的。但是，其余情况，并不完全一致。

5 标准化补充

实际上 PCA 标准化是很重要的，不进行这一步是会导致不同的结果的，这也是为什么标准化过后才与 SVD 一致。

首先扯一个话题，SVD 和 PCA 谁更大，当然这个不好比较。这是一个读者问我的，他的疑惑是 PCA 有不标准化的推导，而标准过后与 SVD 一致，是不是 PCA 更大呢？

笔者觉得这个问题很有意思。量纲会对数据产生影响，不标准化的 PCA 结果可能不同。从几何角度看，因为量纲的影响会导致数据区域变形，比如极度扁平的椭圆。所以人为的标准化消除这种影响。

笔者觉得硬要比较大小的话还是 SVD 大。PCA 量纲问题还是因为它只是正交旋转，但是 SVD 具有坐标轴压缩变换。对于其它场景呢，笔者觉得依旧是 SVD 大，主要是因为 SVD 更加深入矩阵的几何本质。