

SVD

QwanxingxuA

2026 年 8 月 29 日

SVD 是一种降维方法，可以将稀疏矩阵压缩成稠密矩阵，这对于释放存储内存是很好的方法。SVD 是一种数学方法，笔者乘机练习一下英语（笔者英语并不好，可能出现错误）。

1 SVD

Let $A \in \mathbb{R}^{m \times n}$ be a rectangular matrix of rank $r \in [0, \min(m, n)]$. The SVD of A is a decomposition of the form

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$

This is a constructive procedure. We first construct $\mathbf{\Sigma}_{m \times n}$ and $\mathbf{V}_{n \times n}$.

Assume $m \geq n$. $\mathbf{A}^T \mathbf{A}_{n \times n}$ is a symmetric matrix with non-negative eigenvalues. Consider an eigenvector $\mathbf{x}$ and corresponding eigenvalue λ

$$\|\mathbf{A}\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda \|\mathbf{x}\|^2$$

then

$$\lambda = \frac{\|\mathbf{A}\mathbf{x}\|^2}{\|\mathbf{x}\|^2} \geq 0$$

Because $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}^T \mathbf{A}) = r$, We can get an eigenvalue sequence

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r \geq 0, \quad \lambda_{r+1} = \cdots = \lambda_n = 0$$

and corresponding singular value sequence

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0, \quad \sigma_{r+1} = \cdots = \sigma_n = 0$$

since

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \dots, n$$

Let

$$\mathbf{V}_1 = [\mu_1 \quad \mu_2 \quad \dots \quad \mu_r], \quad \mathbf{V}_2 = [\mu + r + 1 \quad \dots \quad \mu_n]$$

where $\mu_1, \mu_2, \dots, \mu_r$ are positive eigenvalues' corresponding eigenvectors and $\mu + r + 1, \dots, \mu_n$ are zero eigenvalues' corresponding eigenvectors.

Construct

$$\mathbf{V} = [\mathbf{V}_1 \quad \mathbf{V}_2]$$

Let

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix}$$

then construct

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}$$

We can find that $\mathbf{V}_2$ is null space of $\mathbf{A}^T \mathbf{A}$ so null space of $\mathbf{A}$, i.e.

$$\mathbf{A} \mathbf{V}_2 = 0$$

Since $\mathbf{V}$ is orthogonal matrix

$$\mathbf{I} = \mathbf{V}^T \mathbf{V}$$

$$\mathbf{A} = \mathbf{A} \mathbf{I} = \mathbf{A} [\mathbf{V}_1 \quad \mathbf{V}_2] [\mathbf{V}_1 \quad \mathbf{V}_2]^T = \mathbf{A} \mathbf{V}_1 \mathbf{V}_1^T$$

We second construct $\mathbf{U}_{m \times m}$. Let

$$\mathbf{u}_j = \frac{\mathbf{A} \boldsymbol{\mu}_j}{\sigma_j}$$

$$\mathbf{U} = [u_1 \quad u_2 \dots u_r \mid u_{r+1} \dots u_m] = [\mathbf{U}_1 \quad \mathbf{U}_2]$$

so

$$\begin{aligned} \mathbf{u}_i \mathbf{u}_j &= \frac{\boldsymbol{\nu}_i^T \mathbf{A}^T \mathbf{A} \boldsymbol{\nu}_j}{\sigma_i \sigma_j} \\ &= \frac{\sigma_j}{\sigma_i} \boldsymbol{\nu}_i \boldsymbol{\nu}_j \\ &= 0 \end{aligned}$$

$$\mathbf{A}\mathbf{V}_1 = \mathbf{U}_1\mathbf{\Sigma}_1$$

then $\mathbf{U}_1$ is orthogonal matrix.

Finally, we can get

$$\mathbf{A} = [\mathbf{U}_1 \quad \mathbf{U}_2] \begin{bmatrix} \mathbf{\Sigma}_1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix} = \mathbf{U}_1\mathbf{\Sigma}_1\mathbf{V}_1^T = \mathbf{A}\mathbf{V}_1\mathbf{V}_1^T$$

and to make $\mathbf{U}$ orthonormal, let

$$[u_{r+1} \quad u_{r+2} \quad \dots \quad u_m] \in \mathcal{N}(\mathbf{A}^T)$$

2 紧奇异值分解、截断奇异值分解与矩阵近似

紧奇异值分解就是原始秩的分解，即 $k = \text{rank}(\mathbf{A}) = r$ 。截断奇异值分解是在秩 $0 < k < r$ 的奇异值分解，即

$$\mathbf{A} \approx \mathbf{U}_k\mathbf{\Sigma}_k\mathbf{V}_k^T$$

要理解它们的不同需要先理解奇异值分解到底在干什么。

从几何上看，我们可以将一个矩阵视为一种变换。即

$$\mathbf{x} \rightarrow \mathbf{A}\mathbf{x}$$

于是可以得到

$$\mathbf{x} \rightarrow \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}$$

所以 $\mathbf{A}$ 与 $\mathbf{x} \rightarrow \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}$ 是一种等价的变换，即奇异值分解就是将原变换分解成了几种变换。




图 16.1 奇异值分解的几何解释

图 1: SVD 分解示意图

由图， V^T 是 $\mathbb{R}^n$ 上的坐标旋转或者反射变换； Σ 是坐标轴的伸缩变换； U 是咋 $\mathbb{R}^n$ 上的坐标旋转或者反射变换。截断奇异值分解，就是对原始完全的变换做出截断。

矩阵近似在几何上理解就是近似变换。对原始矩阵 A 直接修改来近似是很难入手的，截断近似提供了一种方法。那么怎么衡量近似的程度呢？这个问题一般通过距离或者近似度来衡量。距离往往更加直接，矩阵距离无法直接表示，但是可以参考向量的 $L2$ 范数。

弗罗贝乌斯范数：

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{\frac{1}{2}}$$

对于奇异值分解：

$$\|A\|_F = (\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_r^2)^{\frac{1}{2}}$$

所以最优近似是解决如下优化问题：假设所有截断矩阵集合为 $\mathcal{M}$

$$\mathbf{X} = \arg \min_{\mathbf{X} \in \mathcal{M}} \|\mathbf{A} - \mathbf{X}\|_F^2$$

这个问题很好解，因为 Σ 是由大到小排列的。所以对于特定的 k ，当

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_k & & \\ & & & \ddots & \\ & & & & 0 \end{bmatrix} = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix}$$

$$\|\mathbf{A} - \mathbf{X}_k\|_F^2 = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \cdots + \sigma_r^2)$$

时最优。

3 近似思路扩展

上述解决了最优近似问题。但是在机器学习尤其是数据处理部分的时候，这个近似方法非常多。

笔者在语义分析的时候使用过奇异值分解。具体就是解决词向量矩阵稀疏的问题，导致这个问题的主要原因是数据不够多，直接增大数据集是一种有效的办法。但是增加数据也会出现稀疏或者局部稀疏的问题，这是由于数据分布问题导致的，所以压缩数据是数据稠密是必须的。因为这可以提高计算效率也可以减少存储成本。

可以尝试确定 k 值来截断，但是有一个问题：最优求解是很容易得到的，但是希望压缩的目标不仅仅是贴合原始变换，还是需要最优压缩的。这意味着，对于每个 k 还有很多近似矩阵需要查找优化，但是它们的差异其实不算大。

所以有更跳跃的想法。比如就取矩阵 $\mathbf{U}$ 或者 $\mathbf{V}$ 或者 Σ 或者诸如 $\mathbf{U}\Sigma$ 的组合作为近似矩阵，这一步可以跳很远。

还可以有其它的思想，譬如以奇异值为参考，即认为坐标轴变换大的是主要因素，直接提取最主要因素相关的 $\mathbf{U}$ 或者相关分解或者组合作为近似矩阵。

当然，词向量压缩是一个复杂的工作。没有说哪种方法就一定好。