

支持向量机

QwanxingxuA

2026 年 8 月 1 日

Part I

线性可分支持向量机与硬间隔最大化

1 简述

线性可分支持向量机的思想在感知机那一章已经讨论了很多，笔者从策略的角度重点探讨了损失函数方法。本 Part 将从函数间隔、几何间隔的角度严格推导感知机那一节论述的思想。考虑本文仅是学习推导，不是严格的数学专著，相关前提定义在感知机文档中已经给出，本文不再重复定义，直接使用。

2 函数间隔与几何间隔

对于给定数据集 D 和超平面 $(\mathbf{w}, b)$ ，假设超平面 $(\mathbf{w}, b)$ 可以正确分类数据集 D 。

超平面 $(\mathbf{w}, b)$ 关于样本 $(\mathbf{x}_i, y_i)$ 的函数间隔：

$$\hat{\gamma}_i = y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$$

超平面 $(\mathbf{w}, b)$ 关于数据集 D 的函数间隔：

$$\hat{\gamma} = \min_{i=1,2,\dots,n} \hat{\gamma}_i$$

超平面 $(\mathbf{w}, b)$ 关于样本 $(\mathbf{x}_i, y_i)$ 的几何间隔:

$$\gamma_i = \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

超平面 $(\mathbf{w}, b)$ 关于数据集 D 的几何间隔:

$$\gamma = \min_{i=1,2,\dots,n} \gamma_i$$

实际上, 这里的两种间隔就对应于感知机中讨论的两种策略(感知机考虑的是分类错误的样本)。函数间隔会随参数等比例缩放而改变, 不具备尺度不变性; 几何间隔消除了参数缩放带来的影响, 定义唯一。从置信度的角度考虑, 几何间隔衡量了分类正确的置信程度。对应感知机章节的结论: 几何间隔不要求样本越过分界超平面, 还要将样本到超平面的距离纳入评价, 这点后续优化问题会进一步体现。

更深入的说, 两种优化目标对应不同策略, 对泛化误差带来不同影响。之前论述过, 不同的策略会影响泛化误差及其上界。函数间隔仅保证样本分类正确; 几何间隔追求更大的分离余量, 模型泛化能力更强。换言之, 几何间隔最小化策略对应的风险误差或者其上界在概率意义上更小。

最后要强调一点, 不能直接把感知机思路完全套用到支持向量机。虽然函数间隔、几何间隔的概念一致, 但感知机是以误分类样本为出发点; 线性可分 SVM 建立在所有样本分类正确的前提之上开展优化。

3 间隔最大化

基于上述讨论, 可以给出基于几何间隔最大化的优化问题:

$$\begin{aligned} \max \quad & \gamma \\ \text{s.t.} \quad & \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|} \geq \gamma, \quad i = 1, 2, \dots, n \end{aligned}$$

代入几何间隔定义, 问题可以转换为:

$$\begin{aligned} \max \quad & \hat{\gamma} \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq \hat{\gamma}, \quad i = 1, 2, \dots, n \end{aligned}$$

由于超平面具备尺度不变性: 若 $(\mathbf{w}, b)$ 是可行解, 则对任意 $k > 0$, $(k\mathbf{w}, kb)$ 对应同一超平面, 函数间隔同步缩放 k 倍。因此 $\hat{\gamma}$ 的取值不影响

该问题最优解，我们可以人为归一化取 $\hat{\gamma} = 1$ ：

$$\begin{aligned} \max \quad & \frac{1}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, n \end{aligned}$$

最大化 $\frac{1}{\|\mathbf{w}\|}$ 等价于最小化 $\frac{1}{2}\|\mathbf{w}\|^2$ ，问题转换为：

$$\begin{aligned} \min \quad & \frac{1}{2}\|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, n \end{aligned}$$

到此便将原问题转换为典型的凸二次规划问题。书中直接假设最优解下一定存在样本使得约束取等，初次阅读容易产生疑惑：为什么最优解必然落在约束边界？关键结论：目标函数 $\frac{1}{2}\|\mathbf{w}\|^2$ 是严格凸函数，可行域为凸集；严格凸优化问题的最优解必然位于可行域边界。直观理解：若某组可行解全部约束严格大于 1，我们可以等比例缩小 $\|\mathbf{w}\|$ ，进一步优化目标，因此内部点不可能成为最优解。

下面证明几何间隔最大化问题最优解 $(\mathbf{w}^*, b^*)$ 存在且唯一。

(1) 存在性上述问题可行域由一组线性不等式约束构成，是凸集；目标函数为二次正定函数，强制有下界。因此该凸优化问题一定存在最优解 $(\mathbf{w}^*, b^*)$ 。

(2) 唯一性假设存在两个不同最优解 $(\mathbf{w}_1, b_1), (\mathbf{w}_2, b_2)$ ，满足 $\|\mathbf{w}_1\| = \|\mathbf{w}_2\| = c$ 。令 $\mathbf{w} = \frac{\mathbf{w}_1 + \mathbf{w}_2}{2}$ ，由三角不等式：

$$c \leq \|\mathbf{w}\| \leq \frac{\|\mathbf{w}_1\| + \|\mathbf{w}_2\|}{2} = c$$

上式取等号成立的充要条件是 $\mathbf{w}_1, \mathbf{w}_2$ 同向共线，因此：

$$\mathbf{w}^* = \mathbf{w}_1 = \mathbf{w}_2$$

设最优超平面正负间隔边界上分别存在支持向量 $\mathbf{x}'$ （正类）、 $\mathbf{x}''$ （负类），则：

$$\begin{aligned} b_1 &= -\frac{1}{2}(\mathbf{w}^* \cdot \mathbf{x}'_1 + \mathbf{w}^* \cdot \mathbf{x}''_1) \\ b_2 &= -\frac{1}{2}(\mathbf{w}^* \cdot \mathbf{x}'_2 + \mathbf{w}^* \cdot \mathbf{x}''_2) \end{aligned}$$

于是

$$b_1 - b_2 = -\frac{1}{2}\mathbf{w}^* \cdot [(\mathbf{x}'_1 - \mathbf{x}'_2) + (\mathbf{x}''_1 - \mathbf{x}''_2)]$$

又由约束条件：

$$\begin{aligned} \mathbf{w}^* \cdot \mathbf{x}'_2 + b_1 &\geq 1 = \mathbf{w}^* \cdot \mathbf{x}'_1 + b_1 \\ -(\mathbf{w}^* \cdot \mathbf{x}''_2 + b_1) &\geq 1 = -(\mathbf{w}^* \cdot \mathbf{x}''_1 + b_1) \end{aligned}$$

推得

$$\begin{aligned} \mathbf{x}'_1 &= \mathbf{x}'_2, \quad \mathbf{x}''_1 = \mathbf{x}''_2 \\ b_1 - b_2 &= 0 \end{aligned}$$

综上：

$$(\mathbf{w}_1, b_1) = (\mathbf{w}_2, b_2)$$

证毕！

到此便可以引入支持向量概念。如下图，边界 $\mathbf{w} \cdot \mathbf{x} + b = \pm 1$ 构成两条间隔边界 H_1 、 H_2 ，它们之间的距离是 $\frac{2}{\|\mathbf{w}\|}$ 。可以试想，若归一化不取 1，仅带来参数整体缩放，超平面与间隔距离保持不变，本质等价，这也印证了前面尺度不变性的结论。




图 1: 支持向量示意图

4 对偶算法

对偶算法是最优化的一种方法，上述基于几何间隔策略得到原始最优化问题。这个问题具有很好的特性：约束函数满足凸性；该问题满足强对偶性。更好的消息是 KKT 条件支撑了超平面的确立。

构建拉格朗如函数：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i [(1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b))] = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i + b) + \sum_{i=1}^n \alpha_i$$

其中, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$ 是拉格朗日乘子向量。

对偶问题是极大极小化问题, 先解极小化问题:

$$\begin{aligned}\nabla_{\mathbf{w}} L &= \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 \\ \nabla_b L &= \sum_{i=1}^n \alpha_i y_i = 0 \\ \Rightarrow \mathbf{w} &= \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i y_i = 0\end{aligned}$$

代回拉格朗日函数得到极大化问题:

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^n \alpha_i$$

将上述问题转换为标准形式:

$$\begin{aligned}\min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, n\end{aligned}$$

解决这个最优化问题得到最优解 $\alpha^*, \mathbf{w}^*, b^*$ 。依据最优化理论, 它们分别是对偶问题和原始问题的最优解。通过 KKT 条件可以得到原始问题的具体解:

KKT 部分条件:

$$\begin{aligned}\mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i &= 0 \\ \alpha_i^* [1 - y_i (\mathbf{w} \cdot \mathbf{x}_i + b)] &= 0, \quad i = 1, 2, \dots, n \\ \alpha_i^* &\geq 0, \quad i = 1, 2, \dots, n\end{aligned}$$

一定存在 $\alpha_j^* = 0$ 。通过反证法证明, 假设不存在, 那么 $\alpha^* = 0$, 于是 $\mathbf{w}^* = 0$ 。代入原始问题发现这不是最优解, 假设不成立。

结合第二个 KKT 条件可以得到:

$$1 - y_j (\mathbf{w} \cdot \mathbf{x}_j + b) = 0$$

考虑到 $y_i^2 = 1$ 的特性:

$$b = y_j - \mathbf{w} \cdot \mathbf{x}_j$$

整理出来得到超平面

$$\left(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad y_j - \sum_{i=1}^n \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{x}_j) \right)$$

基于 KKT 条件我们发现会出现样本满足 $y_i(\mathbf{w}^* \cdot \mathbf{x}_i + b^*) = 1$, 它们便是支持向量。

Part II

线性支持向量机与软间隔最大化

1 线性支持向量机

线性支持向量机针对线性不可分数据。通常情况下可以将噪声或者特异点去除通过线性可分支持向量机解决。线性支持向量机可以直接处理, 这点与感知机有点类似, 但一定要注意感知机是无法突破线性的, 多层感知机是可以突破线性的。

线性支持向量机添加松弛变量 ξ 。松弛变量这个名称取得非常形象, 在当下问题就是将线性分开的限制松弛一点, 从数学的角度上看是将线性可分支持向量机中的约束松弛一点, 即 $y_i(\mathbf{w} \cdot \mathbf{x}_i) \geq 1 - \xi_i$ 。但松弛肯定不能过度, 于是加上惩罚性来限制松弛, 这点与正则化是一致的。于是可以得到最优化问题:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i, \quad i = 1, 2, \dots, n \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i) \geq 1 - \xi_i, \quad i = 1, 2, \dots, n \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, n \end{aligned}$$

后续同线性可分支持向量机一致, 不在赘述。

2 对偶算法

构造拉格朗如函数：

$$L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i + b) + \sum_{i=1}^n \alpha_i (1 - \xi_i) - \sum_{i=1}^n \mu_i \xi_i$$

通过解决极小化问题得到：

$$\begin{aligned} \min_{\boldsymbol{\alpha}, \boldsymbol{\mu}} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n \end{aligned}$$

这里的最后一个约束实际上是原本多个约束的等价形式。

通过 KKT 条件可以得到：

$$\begin{aligned} \mathbf{w}^* &= \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \\ \alpha_i^* [1 - \xi_i - y_i (\mathbf{w}^* \cdot \mathbf{x}_i + b^*)] &= 0, \quad i = 1, 2, \dots, n \\ \mu_i^* \xi_i &= 0, \quad i = 1, 2, \dots, n \\ C - \alpha_i - \mu_i &= 0, \quad i = 1, 2, \dots, n \end{aligned}$$

如果存在 $0 < \alpha_j < C$, 则 $b^* = y_j - \sum_{i=1}^n \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$, 注意这里要结合最后一个 KKT 条件。

如果 $\alpha_j = C$, 若 $0 < \xi_i < 1$, 则分类正确；若 $\xi_i = 1$, 则在超平面上；若 $0 < \xi_i > 1$, 则分类错误, 这实际是该问题的支持向量, 可见下图。




图 2: 线性支持向量

等价形式与感知机对比分析

对偶问题具有等价的形式, 即合页损失函数:

$$\min_{\mathbf{w}, b} \sum_{i=1}^n [1 - y_i(\mathbf{w}_i \cdot \mathbf{x}_i + b)]_+ + \lambda \|\mathbf{w}\|^2$$

令 $[1 - y_i(\mathbf{w}_i \cdot \mathbf{x}_i + b)]_+ = \xi_i$ 得到等价形式:

$$\min_{\mathbf{w}, b, \xi} \sum_{i=1}^n \xi_i + \lambda \|\mathbf{w}\|^2$$

令 $\lambda = \frac{1}{2C}$:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{C} (C \sum_{i=1}^n \xi_i + \frac{1}{2} \|\mathbf{w}\|^2)$$

从策略角度看, 这是将分类错误纳入经验误差。模型希望减少错误分类, 有感知机的意思。实际上感知机也可以写成上述形式:

$$\min_{\mathbf{w}, b} [y_i(\mathbf{w} \cdot \mathbf{x}_i)]_+$$

可以发现软间隔考虑了确信度, 这与前文感知机与支持向量机对比分析相印证。