

# 支持向量机

QwanxingxuA

2026 年 7 月 31 日

## Part I

# 线性可分支持向量机与硬间隔最大化

## 1 简述

线性可分支持向量机的思想在感知机那一章已经讨论了很多，笔者从策略的角度重点探讨了损失函数方法。本 Part 将从函数间隔、几何间隔的角度严格推导感知机那一节论述的思想。考虑本文仅是学习推导，不是严格的数学专著，相关前提定义在感知机文档中已经给出，本文不再重复定义，直接使用。

## 2 函数间隔与几何间隔

对于给定数据集  $D$  和超平面  $(\mathbf{w}, b)$ ，假设超平面  $(\mathbf{w}, b)$  可以正确分类数据集  $D$ 。

超平面  $(\mathbf{w}, b)$  关于样本  $(\mathbf{x}_i, y_i)$  的函数间隔：

$$\hat{\gamma}_i = y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$$

超平面  $(\mathbf{w}, b)$  关于数据集  $D$  的函数间隔：

$$\hat{\gamma} = \min_{i=1,2,\dots,n} \hat{\gamma}_i$$

超平面  $(\mathbf{w}, b)$  关于样本  $(\mathbf{x}_i, y_i)$  的几何间隔:

$$\gamma_i = \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

超平面  $(\mathbf{w}, b)$  关于数据集  $D$  的几何间隔:

$$\gamma = \min_{i=1,2,\dots,n} \gamma_i$$

实际上, 这里的两种间隔就对应于感知机中讨论的两种策略(感知机考虑的是分类错误的样本)。函数间隔会随参数等比例缩放而改变, 不具备尺度不变性; 几何间隔消除了参数缩放带来的影响, 定义唯一。从置信度的角度考虑, 几何间隔衡量了分类正确的置信程度。对应感知机章节的结论: 几何间隔不要求样本越过分界超平面, 还要将样本到超平面的距离纳入评价, 这点后续优化问题会进一步体现。

更深入的说, 两种优化目标对应不同策略, 对泛化误差带来不同影响。之前论述过, 不同的策略会影响泛化误差及其上界。函数间隔仅保证样本分类正确; 几何间隔追求更大的分离余量, 模型泛化能力更强。换言之, 几何间隔最小化策略对应的风险误差或者其上界在概率意义上更小。

最后要强调一点, 不能直接把感知机思路完全套用到支持向量机。虽然函数间隔、几何间隔的概念一致, 但感知机是以误分类样本为出发点; 线性可分 SVM 建立在所有样本分类正确的前提之上开展优化。

### 3 间隔最大化

基于上述讨论, 可以给出基于几何间隔最大化的优化问题:

$$\begin{aligned} \max \quad & \gamma \\ \text{s.t.} \quad & \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|} \geq \gamma, \quad i = 1, 2, \dots, n \end{aligned}$$

代入几何间隔定义, 问题可以转换为:

$$\begin{aligned} \max \quad & \hat{\gamma} \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq \hat{\gamma}, \quad i = 1, 2, \dots, n \end{aligned}$$

由于超平面具备尺度不变性: 若  $(\mathbf{w}, b)$  是可行解, 则对任意  $k > 0$ ,  $(k\mathbf{w}, kb)$  对应同一超平面, 函数间隔同步缩放  $k$  倍。因此  $\hat{\gamma}$  的取值不影响

该问题最优解，我们可以人为归一化取  $\hat{\gamma} = 1$ ：

$$\begin{aligned} \max \quad & \frac{1}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, n \end{aligned}$$

最大化  $\frac{1}{\|\mathbf{w}\|}$  等价于最小化  $\frac{1}{2}\|\mathbf{w}\|^2$ ，问题转换为：

$$\begin{aligned} \min \quad & \frac{1}{2}\|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, n \end{aligned}$$

到此便将原问题转换为典型的凸二次规划问题。书中直接假设最优解下一定存在样本使得约束取等，初次阅读容易产生疑惑：为什么最优解必然落在约束边界？关键结论：目标函数  $\frac{1}{2}\|\mathbf{w}\|^2$  是严格凸函数，可行域为凸集；严格凸优化问题的最优解必然位于可行域边界。直观理解：若某组可行解全部约束严格大于 1，我们可以等比例缩小  $\|\mathbf{w}\|$ ，进一步优化目标，因此内部点不可能成为最优解。

下面证明几何间隔最大化问题最优解  $(\mathbf{w}^*, b^*)$  存在且唯一。

(1) 存在性上述问题可行域由一组线性不等式约束构成，是凸集；目标函数为二次正定函数，强制有下界。因此该凸优化问题一定存在最优解  $(\mathbf{w}^*, b^*)$ 。

(2) 唯一性假设存在两个不同最优解  $(\mathbf{w}_1, b_1), (\mathbf{w}_2, b_2)$ ，满足  $\|\mathbf{w}_1\| = \|\mathbf{w}_2\| = c$ 。令  $\mathbf{w} = \frac{\mathbf{w}_1 + \mathbf{w}_2}{2}$ ，由三角不等式：

$$c \leq \|\mathbf{w}\| \leq \frac{\|\mathbf{w}_1\| + \|\mathbf{w}_2\|}{2} = c$$

上式取等号成立的充要条件是  $\mathbf{w}_1, \mathbf{w}_2$  同向共线，因此：

$$\mathbf{w}^* = \mathbf{w}_1 = \mathbf{w}_2$$

设最优超平面正负间隔边界上分别存在支持向量  $\mathbf{x}'$ （正类）、 $\mathbf{x}''$ （负类），则：

$$\begin{aligned} b_1 &= -\frac{1}{2}(\mathbf{w}^* \cdot \mathbf{x}'_1 + \mathbf{w}^* \cdot \mathbf{x}''_1) \\ b_2 &= -\frac{1}{2}(\mathbf{w}^* \cdot \mathbf{x}'_2 + \mathbf{w}^* \cdot \mathbf{x}''_2) \end{aligned}$$

于是

$$b_1 - b_2 = -\frac{1}{2}\mathbf{w}^* \cdot [(\mathbf{x}'_1 - \mathbf{x}'_2) + (\mathbf{x}''_1 - \mathbf{x}''_2)]$$

又由约束条件：

$$\begin{aligned} \mathbf{w}^* \cdot \mathbf{x}'_2 + b_1 &\geq 1 = \mathbf{w}^* \cdot \mathbf{x}'_1 + b_1 \\ -(\mathbf{w}^* \cdot \mathbf{x}''_2 + b_1) &\geq 1 = -(\mathbf{w}^* \cdot \mathbf{x}''_1 + b_1) \end{aligned}$$

推得

$$\begin{aligned} \mathbf{x}'_1 &= \mathbf{x}'_2, \quad \mathbf{x}''_1 = \mathbf{x}''_2 \\ b_1 - b_2 &= 0 \end{aligned}$$

综上：

$$(\mathbf{w}_1, b_1) = (\mathbf{w}_2, b_2)$$

证毕！

到此便可以引入支持向量概念。如下图，边界  $\mathbf{w} \cdot \mathbf{x} + b = \pm 1$  构成两条间隔边界  $H_1$ 、 $H_2$ ，它们之间的距离是  $\frac{2}{\|\mathbf{w}\|}$ 。可以试想，若归一化不取 1，仅带来参数整体缩放，超平面与间隔距离保持不变，本质等价，这也印证了前面尺度不变性的结论。




图 1: 支持向量示意图

## 4 对偶算法

对偶算法是最优化的一种方法，上述基于几何间隔策略得到原始最优化问题。这个问题具有很好的特性：约束函数满足凸性；该问题满足强对偶性。更好的消息是 KKT 条件支撑了超平面的确立。

构建拉格朗如函数：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i [(1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b))] = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i + b) + \sum_{i=1}^n \alpha_i$$

其中,  $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$  是拉格朗日乘子向量。

对偶问题是极大极小化问题, 先解极小化问题:

$$\begin{aligned}\nabla_{\mathbf{w}} L &= \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 \\ \nabla_b L &= \sum_{i=1}^n \alpha_i y_i = 0 \\ \Rightarrow \mathbf{w} &= \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i y_i = 0\end{aligned}$$

代回拉格朗日函数得到极大化问题:

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^n \alpha_i$$

将上述问题转换为标准形式:

$$\begin{aligned}\min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \alpha_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, n\end{aligned}$$

解决这个最优化问题得到最优解  $\alpha^*, \mathbf{w}^*, b^*$ 。依据最优化理论, 它们分别是对偶问题和原始问题的最优解。通过 KKT 条件可以得到原始问题的具体解:

KKT 部分条件:

$$\begin{aligned}\mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i &= 0 \\ \alpha_i^* [1 - y_i (\mathbf{w} \cdot \mathbf{x}_i + b)] &= 0, \quad i = 1, 2, \dots, n \\ \alpha_i^* &\geq 0, \quad i = 1, 2, \dots, n\end{aligned}$$

一定存在  $\alpha_j^* = 0$ 。通过反证法证明, 假设不存在, 那么  $\alpha^* = 0$ , 于是  $\mathbf{w}^* = 0$ 。代入原始问题发现这不是最优解, 假设不成立。

结合第二个 KKT 条件可以得到:

$$1 - y_j (\mathbf{w} \cdot \mathbf{x}_j + b) = 0$$

考虑到  $y_i^2 = 1$  的特性:

$$b = y_j - \boldsymbol{w} \cdot \boldsymbol{x}_j$$

整理出来得到超平面

$$(\sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i \quad , \quad y_j - \sum_{i=1}^n \alpha_i y_i (\boldsymbol{x}_i \cdot \boldsymbol{x}_j))$$