

从偏差方差看待机器学习

QwanxingxuA

2026 年 8 月 26 日

本文主要叙述笔者对机器学习的理解，这是笔者在学完线性回归模型、感知机、SVM、最大熵模型、决策树和提升方法后对李航老师在概述里面提到偏差方差的又一次回想理解与总结。

1 数据分布与模型

从线性回归模型、逻辑斯蒂与最大熵模型、CART 回归树到提升树回归树，笔者学习到了各种解决回归问题的机器学习方法，但是一直有一个问题或者困惑。

那就是数据的分布。在学习上述问题的时候，都有一个大前提：针对数据集 D ，我们通过某种方法将其分为训练集和测试集（当然也可以是训练集、评估集、测试集）。实际上在这个前提下，数据的分布发生了变化。在以上的学习过程中通常忽略了这种变化，或者说学习的就是发生了变化的数据分布。在测试集上面我们解决泛化问题，这个思路是正常的。但是无论怎样，总是学习的是变化的分布。于是提出学习多个模型，取均值或者加权重的方法。

回顾机器学习的三要素：模型、策略、算法。那单看模型会发现模型 f 是基于数据的，记作 $\hat{f}_D$ ，其中 D 是某数据集。但是策略、算法是全局的。

这就很有意思了，假设数据集

$$D = \bigcup_{i=1}^n D_i, i = 1, 2, \dots, n \quad n \text{ 可以有限也可以无限}$$

假设以上的学习过程是基于数据集 D_i 的，那么三要素变成：

$$\hat{f}_{D_i}; L(\cdot); F$$

其中 $L(\cdot)$ 是损失函数, F 是某种优化算法。

但是实际上完整的三要素是:

$$\hat{f}_D; L(\cdot); F$$

。

机器学习的大前提是假设数据独立同分布, 但是上面的表达式给出了很有意思的本质: 我们学习的模型的分布是有变化的。

2 损失函数与策略

基于第一节, 笔者发现策略损失函数是全局的。这可能也是损失函数的强大之处, 如果能设计一个优秀的损失函数, 它能够解决数据分布变化带来的影响, 那基于部分数据集训练的模型也能够适配整体的数据集, 那估计也不存在泛化问题了。

但是以上只是猜想, 下面以均方误差为例看看机器学习三要素之一策略的伟大之处。

对于回归问题, 定义真实的模型或者直观的说标签 f_D , 但是标签的说法还是具有局限性, 某些不存在标签的情况其真实模型依然是存在的。

为了方便, 以下推导将 f_D 省略写作 f , 有

$$L(f(x), \hat{f}(x)) = \mathbb{E}([(f(x) + \epsilon) - \hat{f}(x)]^2)$$

其中 ϵ 是扰动, 满足 $\mathbb{E}(\epsilon) = 0, \text{Var}(\epsilon) = \delta^2$ 。将上式展开:

$$L = \mathbb{E}([f(x) - \hat{f}(x)]^2) + 2\mathbb{E}((f(x) - \hat{f}(x))\epsilon) + \mathbb{E}(\epsilon^2)$$

由独立性

$$2\mathbb{E}((f(x) - \hat{f}(x))\epsilon) = 0$$

又

$$\begin{aligned} \mathbb{E}([f(x) - \hat{f}(x)]^2) &= \mathbb{E}(f(x) - \mathbb{E}(\hat{f}(x)) - (\hat{f}(x) - \mathbb{E}(\hat{f}(x))))^2 \\ &= \mathbb{E}(f(x) - \mathbb{E}(\hat{f}(x)))^2 \\ &\quad - 2\mathbb{E}[(f(x) - \mathbb{E}(\hat{f}(x)))(\hat{f}(x) - \mathbb{E}(\hat{f}(x)))] + \mathbb{E}[\hat{f}(x) - \mathbb{E}(\hat{f}(x))]^2 \end{aligned}$$

将第一项展开得到

$$\mathbb{E}(f(x) - \mathbb{E}(\hat{f}(x)))^2 = (f(x) - \hat{f}(x))^2$$

第二项展开

$$-2\mathbb{E}[(f(x) - \mathbb{E}\hat{f}(x))(\hat{f}(x) - \mathbb{E}\hat{f}(x))] = 0$$

于是

$$L(f_D(x), \hat{f}_D(x)) = (f_D(x) - \mathbb{E}\hat{f}_D(x))^2 + \mathbb{E}[\hat{f}_D(x) - \mathbb{E}\hat{f}_D(x)]^2 + \mathbb{E}(\epsilon^2)$$

第一项是真实模型与训练模型期望差的平方，记偏差 Bias 的平方；第二项是训练模型的方差，记 Var。

为了更加直观，以某数据集为例，变为：

$$L(f_D(x), \hat{f}_{D_i}(x)) = (f_D(x) - \mathbb{E}\hat{f}_{D_i}(x))^2 + \mathbb{E}[\hat{f}_{D_i}(x) - \mathbb{E}\hat{f}_{D_i}(x)]^2 + \mathbb{E}(\epsilon^2)$$

上面表达式具有误导性，因为

$$f_D(x) = f_{D_i}(x), \quad x \in D_i \subseteq D$$

这个表达式其实就是在学习线性回归等具体模型时候的损失函数。因为代入具体可得：

$$L(f_D(x), \hat{f}_{D_i}(x)) = (f_D(x) - \hat{f}_{D_i}(x))^2 + \mathbb{E}(\epsilon^2)$$

3 偏差、方差与泛化

前两节已经把前提表达式推导好了，接下来就是笔者以偏差方差为出发点对机器学习的看法了。

看 D_i 的原始表达式：

$$L(f_D(x), \hat{f}_{D_i}(x)) = (f_D(x) - \mathbb{E}\hat{f}_{D_i}(x))^2 + \mathbb{E}[\hat{f}_{D_i}(x) - \mathbb{E}\hat{f}_{D_i}(x)]^2 + \mathbb{E}(\epsilon^2)$$

以上表达式可以论证我们基于数据集 D_i 降低损失函数这一方法的合理性。首先，上表式方差始终为 0，这是显然的，因为这意味着模型完全能够泛化到数据集 D_i （当然一般我们强调的泛化能力是泛化到其它数据集，但是注意学习的模型也是可以泛化到自己本身的数据集，不过这显然是必然的罢了）；其次，损失函数下降也意味着偏差下降，这是为了拟合数据，这显然符合我们的想法，无论是拟合 D_i 还是 D 。

损失函数对于具体模型 f_{D_i} 的合理性

看 D 的表达式：

$$L(f_D(x), \hat{f}_D(x)) = (f_D(x) - \mathbb{E}\hat{f}_D(x))^2 + \mathbb{E}[\hat{f}_D(x) - \mathbb{E}\hat{f}_D(x)]^2 + \mathbb{E}(\epsilon^2)$$

损失函数对于整体模型 f_D 的合理性

我们依旧降低损失函数值，那么最后是偏差和方差都趋近 0。偏差趋于 0 说明每一个模型 D_i 都能很好的拟合数据；方差为 0，意味着不同模型的波动小，即两个模型差距不大，即对数据的敏感度降低，其实就是泛化能力提升。显然是我们想要的。

综上，损失函数这一策略确实是严谨、合理的。

4 总结

以上是笔者的论述过程，其是通过偏差方差论述的。本文实际上重点是讨论机器学习三大要素之一策略。下面笔者将罗列出对机器学习的看法。

- 模型：机器学习的最终目标是找到针对整体数据分布的模型 f_D ；基于部分训练数据集训练的模型 f_{D_i} 的分布是变化的，泛化问题也因此引发。
- 我们平常训练的模型是 f_{D_i} ，损失函数策略才是真的找到或者说靠近 f_D ，这也是为什么泛化能力会直接受损失函数影响。
- 策略：损失函数下降是找到 f_D 的合理方法，这点由偏差和方差严格证明。
- 算法：算法更多是服务于策略的，即服务于找到最终 f_D 。
- 由上述三点，损失函数是非常强大的，其重要性不言而喻。

补充

以上的说法是在忽略一切外部条件的前提下，实际上这里面还受样本数量、模型复杂度等等的影响。