

Bayes

QwanxingxuA

2026 年 8 月 22 日

1 独立同分布

朴素贝叶斯是一种生成模型，即寻找联合分布 $P(x, y)$ 。这离不开独立同分布这一大前提。

在以往的学习过程中实际上基本忽略了这一点，笔者认为写这篇笔记最大的意义就是通过贝叶斯模型巩固独立同分布这一基本前提。

提到独立同分布，必然离不开随机变量。什么是随机变量？笔者认为一切都是随机变量，如输入 x 、输出 y 、输入输出联合 (x, y) 、模型 $f(x)$ 或者 $P(x, y)$ 、损失函数 $L(y, f(x))$ 都是随机变量。

具体的，假设样本空间 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，输入空间 $\mathcal{X} \subseteq \mathcal{R}^m$ ，输出空间 $\mathcal{Y} = \{c_1, c_2, \dots, c_k\}$ 。输入的某一特征 $x_j \in \{a_{j1}, a_{j2}, \dots, a_{jl}\}$ 也是随机变量。

有了随机变量，那么独立同分布到底意味这什么。实际上下面一个表达式就能说明：

$$P(x_{1j}) = P(x_{2j})$$

强调这一点正是以往学习带来了一个直观上面的很大误区。数据集往往存在很多 $(x_1, y_1 = c), (x_2 \neq x_1, y_2 = c)$ 即标签一致输入不一致的样本，这会显得很奇怪，因为给定一个 y ，对应的 x_j 可能是五花八门的，很难想象到它们是独立同分布的。出现这一原因主要还是直观与概率的差距吧。

在初次学习贝叶斯模型的时候，就因为上述误区让笔者觉得自己学会了这一模型。因为基于频率直接给出对应的概率 $P(y | \mathbf{x})$ 是很直观的，但是后来巧合之下细致推导运算过后，才发现这一直观误区带了深刻的影响。笔者得承认，笔者在这种直觉与概率里面想了好几个小时才走出来。

2 生成模型与判别模型

实际上第一节最后笔者所说的误区就是生成模型与判别模型或者说 $P(\mathbf{x}, y)$ 与 $P(y | \mathbf{x})$ 。

为什么这么说呢？换个角度想，现在告诉样本 $\mathbf{x}$ 去看 $P(y)$ ，说 y 独立同分布是很好理解的。但是笔者在告诉 y 去看待 $P(\mathbf{x})$ 的时候陷入了长久的误区。而这一切主要是因为以往的学习都是判别模型。

朴素贝叶斯模型是生成模型。当然知道 $P(\mathbf{x}, y)$ ，能转换成判别模型也是很显然的。

3 朴素贝叶斯

朴素贝叶斯不同与其它很大模型直接给出 $P(\mathbf{x}, y)$ 或者 $P(y | \mathbf{x})$ ，而是一个条件独立假设：

$$P(x_1, x_2, \dots, x_m | y) = \prod_{j=1}^m P(x_j, y)$$

基于贝叶斯定理，可以得到朴素贝叶斯模型：

$$P(y | \mathbf{x}) = \frac{P(y) \prod_{j=1}^m P(x_j | y)}{P(\mathbf{x})}$$

$$P(\mathbf{x}, y) = P(y) \prod_{j=1}^m P(x_j | y)$$

使用负对数极大似然估计

$$\begin{aligned} L &= -\log \prod_{i=1}^n P(y_i) \prod_{j=1}^m P(x_{ij} | y_i) \\ &= -\sum_{i=1}^n \log P(y_i) - \sum_{i=1}^n \sum_{j=1}^m \log P(x_{ij} | y_i) \end{aligned}$$

在很多情况下，基于频率直接获得先验概率 $P(y)$ 、条件概率 $P(x_j | y)$ 。实际上那是假设的，但是贝叶斯模型是生成模型，上述是不能直接获取的，因为 $P(y), P(x_j | y)$ 都是要学习的模型本身。

那怎么办了，实际上就是解决上述优化问题。

关于这一点，李航老师是在习题里面要证明的。如果没有看习题的话，可能自然以为是基于频率了，因为这个表达式就是这样的，那其实就和笔者一样以为自己学会了朴素贝叶斯，实际上根本没有理解朴素贝叶斯模型。

可以发现表达式的两项是没有联系的。所以先处理子问题：

$$\begin{aligned} \min_{P(y=c_k)} L &= - \sum_{i=1}^n \log P(y_i) = - \sum_{k=1}^K \sum_{i=1}^n I(y_i = c_k) \log P(y = c_k) \\ s.t. \quad &\sum_{k=1}^K P(y = c_k) = 1 \end{aligned}$$

构建拉格朗日函数：

$$L = - \sum_{k=1}^K \sum_{i=1}^n I(y_i = c_k) \log P(y = c_k) + \lambda \left(\sum_{k=1}^K P(y = c_k) - 1 \right)$$

求导得到：

$$\frac{\partial L}{\partial P(y = c_k)} = - \frac{\sum_{i=1}^n I(y_i = c_k)}{P(y = c_k)} + \lambda = 0$$

所以

$$\sum_{k=1}^K P(y = c_k) = \sum_{k=1}^K \frac{\sum_{i=1}^n I(y_i = c_k)}{\lambda} = 1$$

于是

$$\begin{aligned} \lambda &= \sum_{k=1}^K \sum_{i=1}^n I(y_i = c_k) = n \\ P(y = c_k) &= \frac{\sum_{i=1}^n I(y_i = c_k)}{n} \end{aligned}$$

这其实就是频率，先验概率 $P(y)$ 具有一般性，很多模型前提假设是有道理的。但是条件概率不具有了一般性了，下面求解第二项的子问题：

$$\begin{aligned} \min_{P(x_j=a_{jl}|y=c_k)} L &= - \sum_{i=1}^n \sum_{j=1}^m \log P(x_{ij} | y_i) = - \sum_{k=1}^K \sum_{i=1}^n \sum_{j=1}^m \log P(x_{ij} | y_i = c_k) \\ s.t. \quad &\sum_{l=1}^L P(x_j = a_{jl} | y = c_k) = 1 \end{aligned}$$

构造拉格朗日函数：

$$L = - \sum_{i=1}^n \sum_{j=1}^m \log P(x_{ij} | y_i) = - \sum_{k=1}^K \sum_{i=1}^n \sum_{j=1}^m \log P(x_{ij} | y_i = c_k) + \lambda \left(\sum_{l=1}^L P(x_j = a_{jl} | y = c_k) - 1 \right)$$

求导:

$$\frac{\partial L}{\partial P(x_j = a_{jl} | y = c_k)} = - \sum_{i=1}^n \frac{I(x_{ij} = a_{jl}, y = c_k)}{P(x_{ij} = a_{jl} | y = c_k)} + \lambda = 0$$

所以

$$\sum_{l=1}^L P(x_j = a_{jl} | y_i = c_k) = \sum_{l=1}^L \frac{\sum_{i=1}^n I(x_{ij} = a_{jl} | y_i = c_k)}{\lambda} = 1$$

于是

$$\lambda = \sum_{i=1}^n I(y_i = c_k)$$

$$P(x_j = a_{jl} | y_i = c_k) = \frac{\sum_{i=1}^n I(x_{ij} = a_{jl}, y_i = c_k)}{\sum_{i=1}^n I(y_i = c_k)}$$

上面便得到模型的解了。这个过程并不容易，建议读者自己证明。

实际上这和最大熵模型是类似的，如果知道一些信息，将它加入约束会得到不一样的模型。

4 贝叶斯估计

贝叶斯估计是在朴素贝叶斯模型之上添加参数，即

$$P(x, y; \alpha)$$

$$P(y = c_k) = \frac{\sum_{i=1}^n I(y_i = c_k) + \alpha}{n + \alpha K}$$

$$P(x_j = a_{jl} | y_i = c_k) = \frac{\sum_{i=1}^n I(x_{ij} = a_{jl}, y_i = c_k)}{\sum_{i=1}^n I(y_i = c_k) + \alpha L}$$

先不证明，但其实从朴素贝叶斯的推导就可以知道分母 α 为什么乘 K 和 L 了。