

二分类问题泛化误差上界

QwanxingxuA

2026 年 7 月 7 日

对于二分类任务，样本空间 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，假设空间 $\mathcal{F} = \{f_1, f_2, \dots, f_d\}$ ，假设 d 有限。

损失函数采用 0-1 损失函数：

$$L(y, f(x))$$

泛化误差实质是风险误差：

$$R(f) = E(L(Y, f(X)))$$

经验误差：

$$\hat{R}(f) = \frac{\sum_{i=1}^n L(y_i, f(x_i))}{n}$$

泛化误差是在概率分布 $P(X, Y)$ 下的。但是我们并不知道 $P(X, Y)$ ，所以我们使用经验误差来寻找最优 f 。泛化误差无法精确衡量，但是可以退其次寻找上界。

对于二分类任务、任意 f ，在至少 $1 - \delta$ 下，泛化误差 $R(f)$ 有上界 $\hat{R}(f) + \varepsilon$ 。

不急证明，先回顾概率论的几个结论。

马尔可夫不等式：

$$P(|X| \geq \varepsilon) \leq \frac{E(|X|)}{\varepsilon}$$

证明：使用可示函数 $I_{\{|X| \geq \varepsilon\}}$ 很容易证明。

马尔可夫推论：

$$P(X \geq \varepsilon) \leq \frac{E(e^{tX})}{e^{t\varepsilon}}$$

引理：随机变量 X 满足 $P(a \leq X \leq b) = 1, E(X) = 0$ ，则

$$P(X \geq \varepsilon) \leq e^{(-t\varepsilon + \frac{(b-a)^2 t^2}{8})}$$

证明： e^{tx} 明显凸函数，有：

$$E(e^{tX}) \leq E\left(\frac{b-x}{b-a}e^{ta} + \frac{x-a}{b-a}e^{tb}\right) = E\left(\frac{b}{b-a}e^{ta} - \frac{a}{b-a}e^{tb}\right)$$

$$\text{令 } g(t) = \ln\left(\frac{b}{b-a}e^{ta} - \frac{a}{b-a}e^{tb}\right), g(0) = 0$$

$$g'(t) = \frac{ba(e^{ta} - e^{tb})}{be^{ta} - ae^{tb}}, g'(0) = 0$$

$$g''(t) = ba \frac{(b-a)^2 e^{ta+tb}}{(be^{ta} - ae^{tb})^2}$$

由基本不等式：

$$g''(t) \leq \frac{(b-a)^2}{4}$$

将 $g(t)$ 在 $t=0$ 处二阶泰勒展开：

$$g(t) = g(0) + g'(0)t + \frac{g''(\epsilon)}{2}t^2 \leq \frac{(b-a)^2 t^2}{8}$$

代回去证毕！

霍夫丁不等式：对于相互独立的随机变量 $X_1, X_2, \dots, X_n$ 满足 $P(a_i \leq X_i \leq b_i) = 1, \bar{X} = \sum_{i=1}^n X_i$ ，则

$$P(X - E(\bar{X}) \geq \varepsilon) \leq e^{-\frac{2n\varepsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}}$$

证明：显然：

$$P\left(\frac{a_i - E(X_i)}{n}\right) \leq \frac{X_i - E(X_i)}{n} \leq \frac{b_i - E(X_i)}{n} = 1$$

$$E\left(\frac{X_i - E(X_i)}{n}\right) = 0$$

$$P(X - E(\bar{X}) \geq \varepsilon) \leq \frac{E(e^{t(X - E(\bar{X}))})}{e^{t\varepsilon}}$$

$$e^{t(X - E(\bar{X}))} = e^{t \sum_{i=1}^n \frac{X_i - E(X_i)}{n}}$$

到这里就可以带入引理了（求和与连乘在独立条件下相互转换，这里省略了）：

$$P(X - E(\bar{X}) \geq \varepsilon) \leq e^{-t\varepsilon + \sum_{i=1}^n \frac{t^2 (b_i - a_i)^2}{8n^2}}$$

这个表达式是关于 t 的任意问题，右侧取关于 t 的二次函数最小值：

$$P(X - E(\bar{X}) \geq \varepsilon) \leq e^{-\frac{2n^2\varepsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}}$$

至此准备工作完毕了！

回到二分类任务，可以发现 $R(f) = E(\hat{R}(f))$

注意这里的 X 关联的是损失函数 $L(Y, f(X))$ ，它的取值 0 或者 1，故而该问题的 a_i 均为 0， b_i 均为 1。

带入霍夫丁不等式：

$$P(R(f) - \hat{R}(f) \geq \varepsilon) \leq e^{-\frac{2n^2\varepsilon^2}{\sum_{i=1}^n (b_i - a_i)^2}} = e^{-2n\varepsilon^2}$$

令 $\delta = e^{-2n\varepsilon^2}$

$$P(R(f) \leq \hat{R}(f) + \varepsilon) \geq 1 - \delta$$

故而在至少 $1 - \delta$ 概率下，找到了泛化误差的上界。

总结下来，损失函数也好，泛化能力也好，它们的本质是我们为了找到最优 f 而确立的评价策略。重要的是，这个策略是从联合概率分布 $P(X, Y)$ 或者条件概率分布 $P(Y|X)$ 或 $P(X|Y)$ 出发的，它们之间必然存在概率上的联系。