

感知机

QwanxingxuA

2026 年 7 月 28 日

1 原始模型

感知机解决的是一个二分类任务，模型结构简单，不再赘述，直接给出模型定义。

样本集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，输入空间 $\mathcal{X} \subseteq \mathbb{R}^m$ ，输出空间 $\mathcal{Y} = \{+1, -1\}$ 。模型假设空间由超平面参数 $(\mathbf{w}, \mathbf{b})$ 构成。具体数学表达：仿射判别函数：

$$g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + \mathbf{b}$$
$$f(\mathbf{x}) = \text{sign}(g(\mathbf{x})) = \begin{cases} +1, & g(\mathbf{x}) \geq 0 \\ -1, & g(\mathbf{x}) < 0 \end{cases}$$

注意：模型假设空间的核心是超平面，而非线性函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + \mathbf{b}$ ，这一点对后续经验误差分析至关重要。

2 经验误差、损失函数

记误分类样本集合为 $\mathcal{M}$ ， $\|\mathbf{w}\|$ 表示权重向量 $\mathbf{w}$ 的 L2 范数。按照李航《统计学习方法》基于误分类样本几何距离的思路，可得到原始误差函数：

$$L(\mathbf{w}, \mathbf{b}) = -\frac{1}{\|\mathbf{w}\|} \sum_{\mathbf{x}_i \in \mathcal{M}} y_i (\mathbf{w} \cdot \mathbf{x}_i + \mathbf{b})$$

书中直接将 $\|\mathbf{w}\|$ 视作常数，直接舍去分母简化损失，此处实在令人费解，该处理方式对初学者不够友好——范数项会直接影响梯度表达式与参数迭代更新规则。我曾询问 AI 相关解释，得到的说法是单次迭代中 $\mathbf{w}$ 变化幅度小，可近似为常数；该解释存在明显逻辑漏洞：1. 若当前 $\|\mathbf{w}\|$ 数值很

小，参数小幅更新也会带来相对尺度的剧烈变化；2. 梯度下降迭代初期远离最优超平面时，单次参数更新量完全可能很大，无法近似恒定。

本质上读者容易被“最小化几何距离”的直观思路误导，两种损失对应的优化策略并不等价。

前文特意强调假设空间本质是超平面而非线性函数，是因为感知机优化并不绑定距离优化方案，也不依赖线性规划框架。模型优化的核心目标仅为减少误分类样本数量，即满足 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) < 0$ 的样本尽可能少，让误分类样本向超平面另一侧跨越。损失函数只需衡量误分类样本的函数间隔，分母 $\|\mathbf{w}\|$ 不会改变最优超平面，仅影响收敛速度。

收敛速度的差异完全可通过调整学习率弥补，书中也引入学习率参与迭代更新，侧面印证无需强行将范数近似为常数。因此我并不认同“ $\|\mathbf{w}\|$ 近似常数”这一解释，更合理的理解是：利用超平面尺度自由度，人为固定 $\|\mathbf{w}\| = 1$ 简化计算。

由此得到工程上常用的简化损失函数：

$$L(\mathbf{w}, \mathbf{b}) = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$$

该损失求梯度形式简洁；基于几何距离的原始损失同样具备理论意义，可自行完成梯度推导练习向量与矩阵求导。

后续补充

上文讨论基于机器学习三要素（模型、策略、算法）与经验风险最小化思想展开，该简化操作存在严谨数学依据，下面给出说明：

对任意常数 $k > 0$ ，参数 $(\mathbf{w}, \mathbf{b})$ 与 $(k\mathbf{w}, k\mathbf{b})$ 对应完全相同的分割超平面，二者给出的分类结果完全一致，即最优分割超平面不唯一对应一组 $(\mathbf{w}, \mathbf{b})$ ：

$$\mathbf{w} \cdot \mathbf{x} + b = 0 \iff k\mathbf{w} \cdot \mathbf{x} + kb = 0$$

利用该尺度等价性，可施加归一约束 $\|\mathbf{w}\| = 1$ ，此时几何间隔损失与简化后的函数间隔损失完全等价，这是教材舍去分母的根本数学原因。

3 收敛性

为了方便，记 $\hat{\mathbf{w}} = (\mathbf{w}^T, b)^T, \hat{\mathbf{x}} = (\mathbf{x}^T, 1)^T$ 。

Novikoff 定理：设训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ 是线性可分的，其中 $x_i \in \mathcal{X} \subseteq \mathbf{R}^n, y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$ ，则

(1) 存在满足条件 $\|\hat{\mathbf{w}}^*\| = 1$ 的超平面 $\hat{\mathbf{w}}^* \cdot \hat{\mathbf{x}} = 0$ 将数据集完全正确分开；且存在 $\gamma > 0$ ，对所有的 $i = 1, 2, \dots, N$ 有：

$$y_i(\hat{\mathbf{w}}^* \cdot \hat{\mathbf{x}}_i) \geq \gamma > 0$$

(2) 令 $R = \max_{1 \leq i \leq N} \|\hat{\mathbf{x}}_i\|$ ，则随机梯度下降法分类次数 k 满足：

$$k \leq \left(\frac{R}{\gamma}\right)^2$$

证明：

在第 $k-1$ 次迭代，假设 (x_i, y_i) 被错误分类

$$y_i(\hat{\mathbf{w}}^{k-1} \cdot \hat{\mathbf{x}}_i) \leq 0$$

$$\hat{\mathbf{w}}^{(k)} = \hat{\mathbf{w}}^{k-1} + \eta y_i \hat{\mathbf{x}}_i$$

$$\hat{\mathbf{w}}^{(k)} \cdot \hat{\mathbf{w}}^* = \hat{\mathbf{w}}^{(k-1)} \cdot \hat{\mathbf{w}}^* + \eta y_i (\hat{\mathbf{w}}^* \cdot \hat{\mathbf{x}}_i) \geq \hat{\mathbf{w}}^{(k-1)} \cdot \hat{\mathbf{w}}^* + \eta \gamma$$

$$\geq \dots \geq k\eta\gamma$$

$$\begin{aligned} \|\hat{\mathbf{w}}^{(k)}\|^2 &= \|\hat{\mathbf{w}}^{(k-1)}\|^2 + 2\eta y_i (\hat{\mathbf{w}}^{(k-1)} \cdot \hat{\mathbf{x}}_i) + \eta^2 \|\hat{\mathbf{x}}_i\|^2 \leq \|\hat{\mathbf{w}}^{(k-1)}\|^2 + \eta^2 R^2 \\ &\leq \dots \leq k\eta^2 R^2 \end{aligned}$$

故而，由柯西不等式：

$$k\eta\gamma \leq \hat{\mathbf{w}}^{(k)} \cdot \hat{\mathbf{w}}^* \leq \|\hat{\mathbf{w}}^{(k)}\| \cdot \|\hat{\mathbf{w}}^*\| \leq \sqrt{k\eta} R$$

所以：

$$k \leq \left(\frac{R}{\gamma}\right)^2$$

证明不难，但是证明是在 $\|\hat{\mathbf{w}}^*\| = 1$ 这一条件下显得简单，当然这个证明是没有问题。笔者稍微提前看了 SVM，某些道理后面才好说，当然如果你数学已经了解凸壳之类的了当我没说（笔者是在习题看到后百度了一下，了解不多）。

4 对偶

笔者学过最优化方法，那里面的对偶问题推导蛮复杂，所以看到这个对偶问题的时候准备大干一场，但是很快发现，很简单。不过系数变参数，至少看上去有点对偶味道了。

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha_i y_i \mathbf{x}_i$$

$$\mathbf{b} \leftarrow \mathbf{b} + \alpha_i y_i$$

n_i 是第 i 个样本被分类错误的次数:

$$\alpha_i = n_i \eta$$

很好理解，参数随机抽取时（当然对偶方法要按一定顺序），参数的变化是由错误样本影响的，影响几次改变几次，所以对偶不一次次迭代，直接看影响次数或者说系数的影响。

使用向量解决问题是非常便于计算的方法，所以取系数向量 α 记录每个样本被分错误的次数。当然书中是写的求和形式，笔者主要受最近 python 影响了，但是思想是一致的。

当然矩阵在计算上也提供了遍历，在某些软硬件架构中也会提高计算效率（基于笔者智能计算学习，可能有误）。Gram 矩阵的诞生也就自然而然了。

$$G = [\mathbf{x}_i \cdot \mathbf{x}_j]_{N \times N}$$

后记

以上内容是在数据的作用下找到最优参数。实际上，参数可以人为设定，并且基于参数可以设置与门、非门、或门，但是无法设置异或门。这是因为异或门具有非线性，而单层感知机只具备线性。数字逻辑告诉我们异或门可以通过与门、或门、非门构造，连接多个感知机便可以实现异或门，也就是多层感知机。可以惊喜的发现，感知机竟然能够构建计算机的组件。事实上，感知机可以表示线性、非线性空间，在理论上可以表示计算机。但是现实中计算机的构建是非常复杂的，参数全权由人设定显然不现实，于是诞生了神经网络，自学习参数，这又和上文机器学习的思想不约而同了。可以发现，简单的模型居然可以具有如此强大的功能，我想这也是 AI 的强大之处。