

线性回归

QwanxingxuA

2026 年 7 月 22 日

线性回归是很简单的模型，也是比较好实现的。李航老师详细介绍了线性回归的方法，但是策略层面对我这种初学者不友好，尤其是概率模型，以下说说我的思路。

1 模型

对于样本空间 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 输入空间 $\mathcal{X} \subseteq \mathbb{R}^m$, 输出空间 $\mathcal{Y} \subseteq \mathbb{R}$ 。基于对数据的初步观察，缩小假设空间到

$$y = \mathbf{w} \cdot \mathbf{x} + b$$

构建模型的本质就是基于对数据的初步观察缩小假设空间。

2 策略

策略是基于已经缩小的假设空间找到最优 f ，通过经验误差或者说损失误差来找到最优，同时尽量让风险误差或者泛化误差小。

2.1 直观非概率

从直观上分析经验误差就是预测值 $\hat{y}$ 与真实值 y 的距离。显然可以得到损失函数

$$L(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{2n} \sum_{i=1}^n [y_i - (\mathbf{w} \cdot \mathbf{x}_i + b)]^2$$

该损失函数优化求解就是线性最小二乘法，见最优化方法：

这里说明一下 $X^T X$ 半正定（这也是李航老师书中题目）：对任意非零向量 $\mathbf{u}$ 有：

$$\mathbf{u}^T X^T X \mathbf{u} = (X\mathbf{u})^T X\mathbf{u} \geq 0$$

2.2 正态分布概率

这是这一章不好理解的点。实际上，这种策略是假设条件概率密度 $p(x, y)$ 服从正态分布。不好理解的关键是与直观距离相比，这里的目标是使得输入 x 的真实值靠近正态分布的最高点。

$$E(y|\mathbf{x}) = E(\mathbf{w} \cdot \mathbf{x} + b|\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b = \hat{y}$$

从均值来看，也可以说是优化参数使得输入 x 的预测值 $\hat{y}$ 在正态分布概率下靠近真实值 y 。

最大似然估计是为了让观察到的数据出现可能性最大，这天然适配上述问题。代入此问题就是使真实数据处于均值，这样数据在真实值附近概率最大。

取似然函数的负数，构成损失函数：

$$L(\mathbf{w}) = \frac{1}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - (\mathbf{w} \cdot \mathbf{x}_i + b)]^2$$

损失函数是用来服务策略的，是个优化问题，可以忽视常数和一些常量，自然可以得到：

$$L(\mathbf{w}) = \frac{1}{2n} \sum_{i=1}^n [y_i - (\mathbf{w} \cdot \mathbf{x}_i + b)]^2$$

这里回到最小二乘法了，李航老师的书就是这么写的，很容易使初学者如我一样忽略概率，凭借直观感受忽略了概率策略的思想。

3 结构风险误差

线性回归模型还有岭回归和 Lasso，它们是两种正则化手段，也就是结构风险误差，实质上还是一种策略。

但是两种损失函数对泛化误差产生了不同影响，这也印证了我在二分类任务泛化误差上界中说的损失函数与泛化误差存在着联系。

总之，线性回归模型是很简单的模型，其中的概率策略实质上就是最大似然估计的思想。作者似乎记得哪个题目要求证明风险误差就是最大似然估计来着，现在的作者实力还不够，慢慢学习理解吧。