

优化方法补充

QwanxingxuA

2026 年 8 月 17 日

鱼书说明了 SGD、Momentum、AdaGrad 方法，本文将说明 Nesterov、RMSprop、Adam 方法。

1 Nesterov

Nesterov 相较于 Momentum 的改进是不在参数 $\mathbf{W}$ 做更新，而是前瞻一个动量单位，具体公式：

$$\begin{aligned}\mathbf{v} &\leftarrow \gamma \mathbf{v} - \eta \frac{\partial L(\mathbf{W} + \beta \mathbf{v})}{\partial \mathbf{W}} \\ \mathbf{W} &\leftarrow \mathbf{W} + \mathbf{v}\end{aligned}$$

该方法是动量法的一种改进，在收敛速度、震荡缓解方面的表现更好。在代码实现方面通常简化处理，因为求解前瞻参数的梯度开销不小。

2 RMSprop

AdaGrad 方法为每个参数调节学习率大小，对于变化大的参数抑制学习率，但是此方法的问题在于迭代历史的叠加会导致梯度更新缓慢。RMSprop 方法相比较加了一个衰减系数，控制历史信息的获取量，但是没有完全避免历史叠加带来的不更新问题，公式：

$$\begin{aligned}\mathbf{h} &\leftarrow \rho \mathbf{h} + (1 - \rho) \frac{\partial L}{\partial \mathbf{W}} \odot \frac{\partial L}{\partial \mathbf{W}} \\ \mathbf{W} &\leftarrow \mathbf{W} - \eta \frac{1}{\sqrt{\mathbf{h}}} \frac{\partial L}{\partial \mathbf{W}}\end{aligned}$$

3 Adam

Adam 实则是对动量法、RMSprop 的结合，考虑了惯性、坡度两个维度，加速收敛速度同时自动调节每个参数：

$$\mathbf{m} \leftarrow \beta_1 \mathbf{m} + (1 - \beta_1) \frac{\partial L}{\partial \mathbf{W}}$$

$$\mathbf{v} \leftarrow \beta_2 \mathbf{v} + (1 - \beta_2) \frac{\partial L}{\partial \mathbf{W}} \odot \frac{\partial L}{\partial \mathbf{W}}$$

偏差校正：

$$\hat{\mathbf{m}} = \frac{\mathbf{m}}{1 - \beta_1^t}$$

$$\hat{\mathbf{v}} = \frac{\mathbf{v}}{1 - \beta_2^t}$$

参数更新：

$$\mathbf{W} \leftarrow \mathbf{W} - \eta \frac{\hat{\mathbf{m}}}{\sqrt{\hat{\mathbf{v}} + \epsilon}}$$